

Автоматическая диагностика неисправностей электродвигателей

Выполнил :Лайла Раби

Группа: 5040102/40201

постановка задачи

- **1-Промышленный вызов:**

Сбои в работе электродвигателей в промышленных условиях приводят к:

- Незапланированным остановкам

- Угрозе безопасности.

- Затратам на техническое обслуживание: реактивное техническое обслуживание обходится в 3–9 раз дороже, чем прогноз.

постановка задачи

2-Техническая проблема :

-Традиционный анализ вибрации требует:

- специалистов для интерпретации результатов
- ручной проверки и периодического контроля

Основываясь на этих проблемах, возникает необходимость в автоматической системе диагностики неисправностей

Цель работы

- Разработка системы автоматического обнаружения неисправностей с использованием машинного обучения, которая может:
 - своевременно обнаруживать дисбаланс, неисправности подшипников и электрические проблемы, что предотвращает внезапные остановки и обеспечивает безопасность работников.

Датасет

- От сайта Kaggle
- Эта датасет состоит из 1951 многомерных временных рядов(multivariate time-series).
- В каждой временной рядой есть выходные данные 8 датчиков
Тахометр , микрофон, 3 акселерометра(аксиальный , радиальный, тангенциальный) (нижняя сторона), 3 акселерометра(аксиальный , радиальный, тангенциальный) (верхняя сторона)
- 5 KHZ , 5 секунд => 250,000 значений для каждого датчика
2000,000 значений в каждом временном ряде

Типы неисправностей

- Эти временные ряды охватывают шесть основных различных состояний

1- Нормальное состояние

2- Горизонтальное смещение(0.5mm ,1mm,1.5mm,2mm)

3-Вертикальное смещение
(0.51mm,0.63mm,1.27mm,1.4mm,1.78mm, 1.9mm)

4-Дисбаланс (6g,10g,15g,20g,25g,30g,35g)

Типы неисправностей

5-Неисправности внешней стороны (overhang)

- Дефект шариков(ball fault)(0g,6g,20g,35g).
- Дефект сепаратора(cage_fault) (0g,6g,20g,35g).
- Дефект внешнего кольца(outer_race) (0g,6g,20g,35g).

6- Неисправности внутренней стороны (underhang)

- Дефект шариков(ball_fault)(0g,6g,20g,35g).
- Дефект сепаратора(cage_fault) (0g,6g,20g,35g).
- Дефект внешнего кольца(outer_race) (0g,6g,20g,35g).

Типы неисправностей

В общей сложности у нас 42 вида неисправностей

Выбор модели

В Kaggle

- Использовали (SVM , K-NN ,DNN)
- Данные были преобразованы в частотную область.
- Они не прогнозировали все неисправности, а только некоторые
- Некоторые из них обнаруживали только аномалии, то есть, работает ли система нормально или нет

Выбор модели

Research article



Prediction of induction motor faults using machine learning

Ademola Abdulkareem^{a,*}, Tochukwu Anyim^a, Olawale Popoola^b, John Abubakar^c,
Agbetuyi Ayoade^a

^a Electrical and Information Engineering Department, Covenant University, P.M.B 1023, Ota, 112212, Ogun State, Nigeria

^b Electrical Engineering Department, Centre for Energy and Electric Power, Faculty of Engineering and the Built Environment, Tshwane University of Technology, Nigeria

^c Department of Computer Science and Engineering, University of Bologna, BO, Italy

ARTICLE INFO

Keywords:

Artificial neural network classifier

Decision tree classifier

Random Forest classifier

k-NN classifier

Induction motors

Predictive maintenance

ABSTRACT

Unplanned downtime in industrial sectors presents significant challenges, impacting both production efficiency and profitability. To tackle this issue, companies are actively working towards optimizing their operations and reducing disruptions that hinder their ability to meet customer demands and financial goals. Predictive maintenance, utilizing advanced technologies like data analytics, machine learning, and IoT devices, offers real-time equipment data monitoring and analysis. This research study centers on the development of a versatile machine-learning model for predicting faults in induction motors within industrial environments. Implementing such a model can enable proactive maintenance, ultimately leading to decreased downtime in industrial operations. The study involved the acquisition of a dataset comprising healthy and faulty conditions of four 3-phase induction motors, along with relevant features for fault prediction. Multiple machine learning algorithms were trained using this dataset, exhibiting promising performance. The Random Forest (RF) model achieved the highest accuracy at 0.91, closely followed by the Artificial Neural Network (ANN) and k-nearest Neighbors (k-NN) models, both achieving an accuracy of 0.9. Meanwhile, the Decision Tree (DT) model showed the lowest ac-

Обработка данных и извлечение признаков

- Извлечение комплексных признаков из каждого сигнала датчика:
 - Статистические признаки (среднее, стандартное отклонение, асимметрия, эксцесс).
 - Признаки формы сигнала (фактор амплитуды, фактор формы).
 - Частотные признаки (спектральный центр, спектральная энтропия).
 - Нелинейные признаки (фрактальная размерность).
 - Анализ пиков и частота пересечения нуля.

Обработка данных и извлечение признаков

45 features для каждого датчика => 360 features для каждой выборки



Обучение моделей

- Разделение данных на обучающую и тестовую выборки

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y_fault, test_size=0.2, random_state=42, stratify=y_fault  
)
```

- Нормализация данных

```
scaler = StandardScaler()  
X_train_scaled = scaler.fit_transform(X_train)  
X_test_scaled = scaler.transform(X_test)
```

Обучение моделей

- Построение и обучение моделей

```
models = {  
    'Random Forest': RandomForestClassifier(  
        n_estimators=1000,  
        max_depth=35,  
        min_samples_split=5,  
        min_samples_leaf=2,  
        max_features='sqrt',  
        bootstrap=True,  
        oob_score=True,  
        n_jobs=-1,  
        random_state=42  
    ),  
    'SVM': SVC(kernel='rbf', random_state=42),  
    'Logistic Regression': LogisticRegression(random_state=42, max_iter=1000)  
}
```

Обучение моделей

```
# Train model
model.fit(X_train_scaled, y_train)

# Predict
y_pred = model.predict(X_test_scaled)

# Calculate accuracy
accuracy = accuracy_score(y_test, y_pred)
```

Обучение моделей

- Результаты обучения трёх моделей

Random Forest:

	precision	recall	f1-score
accuracy			0.92
macro avg	0.93	0.91	0.92
weighted avg	0.92	0.92	0.92

SVM:

	precision	recall	f1-score
accuracy			0.6
macro avg	0.65	0.6	0.6
weighted avg	0.64	0.6	0.6

Обучение моделей

Logistic Regression:

	precision	recall	f1-score
accuracy			0.77
macro avg	0.80	0.78	0.78
weighted avg	0.79	0.77	0.77

Лучшая модель — Random Forest с точностью 92%

Оптимизация модели с помощью GridSearchCV

- Набор параметров, из которых будет выбран наилучший

```
param_grid = {  
    'n_estimators': [500, 1000, 1500],  
    'max_depth': [25, 30, 35, 40, None],  
    'min_samples_split': [2, 3, 5, 7],  
    'min_samples_leaf': [1, 2, 3, 4],  
    'max_features': ['sqrt', 'log2']  
}
```

$$3*5*4*4*2=480$$

Оптимизация модели с помощью GridSearchCV

- Grid Search с кросс-валидацией

```
grid_search = GridSearchCV(  
    best_model,  
    param_grid,  
    cv=5,  
    scoring='accuracy',  
    n_jobs=-1,  
    verbose=1  
)  
grid_search.fit(X_train_scaled, y_train)
```

- Количество обучений: 480 комбинаций × 5 фолдов = 2400 обучений

ОПТИМИЗИРОВАННАЯ МОДЕЛЬ

max_depth	15
max_features	sqrt
min_samples_leaf	1
min_samples_split	5
n_estimators	500

Результаты тестирования на тестовом наборе данных

Overall Accuracy	93.86%
Weighted F1-Score	93.77%
Top-3 Accuracy	99.49%
Top-5 Accuracy	99.74%
Matthews Correlation	0.9372%
Best Class	horizontal_misalignment_0.5mm(F1-Score: 1.000)
Worst Class	imbalance_20g(F1-Score: 0.737)


Сохранение модели

```
joblib.dump(model_data, filename)
```

tkinter приложение

- Загрузка модели
- Введите путь к CSV файлу
- Извлечение признаков из файла и их нормализация
- Вывод
 - Прогнозируемый тип неисправности
 - Уверенность прогноза
 - Топ-6 наиболее вероятных прогнозов с вероятностями

Реальное применение приложения



Спасибо за внимание